

**Вопросы для зачета по курсу
«Статистические модели распознавания» (май 2021)**

1. Байесовские задачи распознавания. Детерминированный характер стратегий байесовского распознавания. Стратегии приближенного решения байесовских задач, основанные на минимизации эмпирического риска.
2. Неравенство Чебышева и его доказательство.
Пусть μ -- математическое ожидание случайной величины x , σ^2 -- её дисперсия, $\bar{X}_n^* = \frac{1}{n} \sum_{i=1}^n X_i$ -- среднее значение величины X_i на случайной выборке длины n . Вывести формулу для оценки сверху вероятности неравенства $|\bar{X}_n^* - \mu| \geq \Delta$.
3. Пусть μ -- математическое ожидание случайной величины x , σ^2 -- её дисперсия, $\bar{X}_n^* = \frac{1}{n} \sum_{i=1}^n X_i$ -- среднее значение величины X_i на случайной выборке длины n . На основании формулы для оценки сверху вероятности неравенства $|\bar{X}_n^* - \mu| \geq \Delta$ вывести формулу для оценки сверху вероятности неравенства $|R^e(d) - R^t(d)| \geq \Delta$, где $R^t(d)$ -- риск решения d , $R^e(d)$ -- эмпирический риск заданного решения d на случайной выборке длины n .
4. Пусть $R^t(d)$ -- риск решения d , $R^e(d)$ -- эмпирический риск решения d на случайной выборке длины n , $d^e = \arg \min_d R^e(d)$. Вывести оценку сверху для величины $R^t(d^e) - \min_d R^t(d)$, если $\forall d \in D [|R^e(d) - R^t(d)| \leq \Delta]$.
5. Пусть $R^t(d)$ -- риск решения d , $R^e(d)$ -- эмпирический риск решения d на случайной выборке длины n , $d^e = \arg \min_d R^e(d)$. Вывести оценку сверху для вероятности того, что условие $\forall d \in D [|R^e(d) - R^t(d)| \leq \Delta]$ не выполнится, и на этом основании показать, как следует выбирать длину эмпирической выборки.
6. Сформулировать и обосновать необходимые и достаточные условия, которым должны удовлетворять условные вероятности $p(x|y)$ и $p(y|x)$, чтобы они однозначно определяли совместные вероятности $p(x, y)$.
7. Сформулировать «алгоритм» отыскания маргинальных вероятностей $p(x)$ и $p(y)$ на основании известных условных вероятностей $p(x|y)$ и $p(y|x)$ и доказать его сходимость. Определить гиббсов саплер и сформулировать его основное свойство.

8. Экспоненциальные случайные величины. Вывести общий вид распределения вероятностей экспоненциальной случайной величины.
9. Гиббсовы поля. Вывести общий вид распределения вероятностей гиббсова поля.
10. Марковские свойства гиббсова поля и гиббсов сэмплер гиббсова поля.
11. Наиболее правдоподобное оценивание параметров экспоненциальной случайной величины.
12. Наиболее правдоподобное оценивание параметров гиббсова поля.
13. Сформулировать понятие рандомизированной стратегии и риска рандомизированной стратегии. Привести пример небайесовской задачи, для которой существует рандомизированная стратегия, риск которой лучше, чем риск любой детерминированной стратегии.
14. Задачи распознавания при неполностью известной статистической модели распознаваемого объекта. Функция риска стратегии. Пригодные и непригодные стратегии.
15. Байесовы стратегии распознавания при статистической модели, известной с точностью до неизвестного параметра. Лемма о дихотомии байесовых и непригодных стратегий.
16. Привести примеры небайесовских задач распознавания: минимаксные задачи, (minimax deviation)-задачи и другие. Показать, что стратегии решения этих задач являются байесовскими, то есть, не являются непригодными.
17. Суперградиент вогнутой функции. Показать, чему равен суперградиент функций $a \cdot f$, $f_1 + f_2$, $\max\{f_1, f_2\}$, если известны суперградиенты функций f , f_1 , f_2 .
18. Сформулировать процесс субградиентного подъема и основное его свойство.
19. Сформулировать алгоритм отыскания стратегии решения минимаксных и (minimax deviation)-задач распознавания.

X - ознака об'єкта, спостереження

$x \in X$ - ми-на спостережень

k - стан об'єкта (приховано вел-ка)

$k \in K$ - ми-на станів

$p(x, k)$ - ймов. того, що об'єкт знаходиться в стані k , а ознака
має об'єкта прийняти x . ~~$p(x, k)$~~

D - ми-на рішень, d - рішення

$W: K \times D \rightarrow \mathbb{R}$ - штрафна ф-я. $W(k, d)$ - штраф, який випливає,
коли об'єкт знаходиться в стані k і прийнято рішення d .

$g: X \rightarrow D$ - стратегія (визначає спостереженням який рішень)

Байєсівська задача:

Дано задані $X, K, D, p_{xk}: X \times K \rightarrow \mathbb{R}, w: K \times D \rightarrow \mathbb{R}$, побудувати
стратегію, яка мінімізує ризик:

$$R(g) = \sum_{x \in X} \sum_{k \in K} p_{xk}(x, k) W(k, g(x))$$

Рішенням байєсівської задачі є стратегія g^* - байєсівська стратегія

рандоміз. стратегія: $g_r: D \times X \rightarrow \mathbb{R}$, ризик рандоміз. стратегії

$$R^{rand}(g) = \sum_{x \in X} \sum_{k \in K} p(x, k) \sum_{d \in D} g_r(d/x) W(k, d).$$

(вже мінімізує)

Теорема

$\exists$ детерм. стратегія $g: X \rightarrow D, R^{det}(g) \leq R^{rand}(g_r)$

$$R^{rand} = \sum_{x \in X} \sum_{d \in D} g_r(d/x) \sum_{k \in K} p(x, k) W(k, d)$$

$$\sum_{d \in D} g_r(d/x) = 1 \quad \forall x \in X, \quad g_r(d/x) \geq 0 \quad \forall d \in D, \quad \forall x \in X$$

$$R^{rand} \geq \sum_{x \in X} \min_{d \in D} \sum_{k \in K} p(x, k) W(k, d).$$

Розглянемо $p(x)$ і знайдемо d , яке робить

$$\sum_{k \in K} p(x, k) w(k, d) = \min_{d \in D} \sum_{k \in K} p(x, k) w(k, d)$$

Визначимо також функцію $q: X \rightarrow D$ є деяким чином сортуємо, щоб не було, ніж рангомізоване, $R^{\text{rand}} \geq \sum_{x \in X} \sum_{k \in K} p(x, k) w(k, q(x))$

Рангомізація не покращує рішення, але в деяких випадках була корисною в силу своїх інших особливостей.

Розглянемо 2 випадки для яких рангомізація є корисною і одержуємо наступні результати.

$$x^* \mapsto d^* = \arg \min_{d \in D} \sum_{k \in K} p(k|x^*) \cdot w(k, d)$$

← тільки функція d

$|D| \cdot |K|$ - складність

але в деяких випадках $|D|$ і $|K|$ є великими і безпосереднього обчислення.

I) Розглянемо випадок, коли $|K|$ - велике, $p(k|x^*)$ - обчислюється просто $|D|$ - мале

Тоді зберігаємо незалежними функції

$k_1, k_2, \dots, k_n$ (у відповідності з розподілом $p(k|x^*)$)

Тоді можна обчислити внутрішній суму $\frac{1}{n} \sum_{i=1}^n w(k_i, d)$

$$\sum_{k \in K} p(k|x^*) w(k, d) \approx \frac{1}{n} \sum_{i=1}^n w(k_i, d)$$

$R^T(d)$

$R^e(d)$

Ідея:

Замість мінімізації можна суму одразу мінімізувати внутрішній суму.

$$\textcircled{\text{II}} \quad x^* \mapsto d^* = \operatorname{argmin}_{d \in D} \sum_{k \in K} p(k/x^*) w(k, d)$$

$d \in \Phi$ функцію від k ($f(k)$ - функція many в-ств значень)
 $|D| < |K|$

$$d = f(k), \quad p(k/x^*) \mapsto \pi(d/x^*)$$

кежаб в задачі як $w(d, d') = w(f(k), d')$

Якщо розглянути π задачі, задача формулюється як

$$d^* = \operatorname{argmin}_{d' \in D} \sum_{d \in D} \pi(d/x^*) w(d, d')$$

якщо не маємо інформації про функції.

Спробуємо в нову, як розглядали $\pi(d/x^*)$?

Прочислюємо $k_1, \dots, k_n$ з розподілу $p(k/x^*)$

Хочемо розглянути $d_1, \dots, d_n$ з розподілом $\pi(d/x^*)$, але ми не
 маємо $\pi(d/x^*)$ навіть і не потрібно знати. Для цього достатньо
 $d_i = f(k_i)$. При такій розподілі $d_1, \dots, d_n$ буде мати розподіл
 $\pi(d/x^*)$. На основі вибірки маємо відновити $\pi(d/x^*)$ (задача як завжди)

2. Нерівність Чебишева і її доведення.
Нехай μ - мат. очікування випадкової величини x , σ^2 - її дисперсія, $x_n^* = \frac{1}{n} \sum_{i=1}^n x_i$ - середнє значення величини x_i на випадковій вибірці довжини n . Вивести формулу для оцінки зверху ймовірності нерівності $|x_n^* - \mu| \leq \Delta$.

$$x \in X, p(x) \geq 0; \sum_{x \in X} p(x) = 1.$$

Нехай $f(x) \rightarrow \mathbb{R}$!

$$\mu = \sum_{x \in X} f(x) p(x) - \text{мат. очікування } f(x).$$

$$\sigma^2 = \sum_{x \in X} (f(x) - \mu)^2 \cdot p(x) - \text{дисперсія } f(x).$$

$$\text{Зрозуміло, що } \sum_{x \in X} (f(x) - \mu) = 0.$$

Якщо дисперсія мала, то ймовірність відхилення ф-ції $f(x)$ від μ тем менше

$$\sigma^2 \text{ задов.} \quad \text{Доведено: } P(|f(x) - \mu| \geq \Delta) \leq \frac{\sigma^2}{\Delta^2} - \text{нерівність Чебишева.}$$

$$\begin{aligned} \sum_{|f(x) - \mu| \geq \Delta} p(x) &= \frac{1}{\Delta^2} \cdot \sum_{|f(x) - \mu| \geq \Delta} \Delta^2 p(x) \leq \frac{1}{\Delta^2} \sum_{|f(x) - \mu| \geq \Delta} (f(x) - \mu)^2 \cdot p(x) \leq \\ &\leq \frac{1}{\Delta^2} \sum_{x \in X} (f(x) - \mu)^2 \cdot p(x) = \frac{\sigma^2}{\Delta^2} \end{aligned}$$

Нехай $x \in X, p_x(x); \mu_x, \sigma_x^2; y \in Y, p_y(y); \mu_y, \sigma_y^2$.

$$\in \varphi\text{-я: } z = x + y; \mu_z = \mu_x + \mu_y$$

$$\sigma_z^2 = \sigma_x^2 + \sigma_y^2, \text{ якщо } x, y - \text{незалежні.}$$

$$\text{Якщо } z = ax \Rightarrow \sigma_z^2 = a^2 \sigma_x^2$$

Нехай $x \in X$, $p(x)$, μ_x , σ_x^2 .

$(x_1, x_2, x_3, \dots, x_m)$ - вибірка взаємно нез-их величин
де неї вважаємо $\frac{1}{m} \sum_{i=1}^m x_i = \bar{x}^m$; Обчислимо μ^m , σ^{2m}
 $\mu^m = \mu_x$; $\sigma^{2m} = \frac{1}{m^2} \sum_{i=1}^m \sigma_m^2 = \frac{m \sigma_m^2}{m^2} = \frac{\sigma_m^2}{m}$

Якщо $|\bar{x}^m - \mu_x| \geq \Delta$: вважаємо, що вибірка "непригодна"

$$\Rightarrow P(|\bar{x}^m - \mu| \geq \Delta) \leq \frac{\sigma^2}{m \Delta^2} \leftarrow \text{з пер-ти Чебишева.}$$

3.

Випадок $(k_1, \dots, k_m)$ називається Δ -примитивним, якщо

$$\forall d \in \mathcal{D}: |R^e(d) - R^T(d)| < \Delta$$

- II - Δ -непримитивним, якщо $\exists d \in \mathcal{D}: |R^e(d) - R^T(d)| \geq \Delta$.

$$x \in X, p(x), p(x) \geq 0, \sum_x p(x) = 1,$$

$$f: X \rightarrow \mathbb{R}, \mu = \sum_{x \in X} f(x) p(x); \sigma^2 = \sum_{x \in X} (f(x) - \mu)^2 p(x)$$

$$\text{Керівництво Чебишева: } P(|f(x) - \mu| \geq \Delta) \leq \frac{\sigma^2}{\Delta^2}$$

$$x \in X, p(x), \mu_x, \sigma_x^2$$

$$(x_1, \dots, x_m) \mapsto \frac{1}{m} \sum_{i=1}^m x_i = X^m, \mu^m, \sigma^{2m}$$

$$\mu^m = \mu_x, \sigma^{2m} = \frac{\sigma_x^2}{m}$$

$$|X^m - \mu_x| \geq \Delta - \text{непримитивна вибірка.}$$

$$P(|X^m - \mu_x| \geq \Delta) \leq \frac{\sigma_x^2}{m \cdot \Delta^2}$$

Вивориставлено в контексті наших понять (ручки, ел. ручки, і т.д.)

$w(k, d)$ - втрачає, які отримувє система, коли прийняв рішення d відносно об'єкта, який знаходиться в стані k .

Для фіксованому d $w(k, d)$ - вип. величина. (т.як k -в.в.)

$$\Rightarrow w(k, d) \text{ має мат. сподівання і дисперсію} = \sigma_w^2(d)$$

Дисперсія невідомо, але меншемо взяти якусь зверху гнз дисперсії

$$\exists \sigma_w^2: \forall d [\sigma_w^2(d) - \sigma_w^2 \leq 0]$$

$$\text{найменша: } \sigma_w^2 = \max_k w(k, d) - \min_k w(k, d)$$

$$R^T(d) = \sum_{k \in \mathcal{K}} p(k|x^0) \cdot w(k,d)$$

берём независимые $k_1, \dots, k_m$ из $p(k|x^0)$ независимо.

$$(k_1, \dots, k_m) \mapsto R^e(d) = \frac{1}{m} \sum_{i=1}^m w(k_i, d)$$

$$\boxed{P(|R^T(d) - R^e(d)| \geq \Delta) \leq \frac{\sigma_w^2}{m \cdot \Delta^2}}$$

4. Нехай $R^T(d)$ - ризик рішення d , $R^e(d)$ - емпіричний ризик рішення d на вибірковій вибірці довжини n , $d^e = \arg \min R^e(d)$. Вивести оцінку зверху для величини $R^T(d^e) - \min_d R^T(d)$, якщо $\forall d \in D [|R^e(d) - R^T(d)| \leq \Delta]$

$x \in X, k \in K$; (x, k) - вимогкова пара.
 Для кожного значення x та k відомо $p(x, k)$, також відома апостеріорна ймовірність $p(k/x)$
 $d \in D$ - кінцева мн-на рішень системи розпізнавання
 $f: X \rightarrow D$; $f(x) \in D$ - стратегія рішень (може бути хорошою чи поганою)

$w: K \times D \rightarrow \mathbb{R}$; $w(k, d)$ - штраф, що виникає системою розпізнавання.
 $R^T(d) = \sum_{k \in K} p(k/x) w(k, d) \leftarrow$ ризик (мат. сподівання) рішення d
 $R^T: D \rightarrow \mathbb{R}$ - тогна функція ризику

Задача: $d^* = \arg \min_d R^T(d)$ (вибрати те рішення, що мінімізує ризик).

Нехай програма видає вибірку $(k_1, \dots, k_m)$
 $R^e(d) = \frac{1}{m} \sum_{i=1}^m w(k_i, d)$ - функція емпіричного ризику
 $\leftarrow$ середнє ариф.

З ростом m R^e стає все ближчим до R^T в тому сенсі, що $|R^e(d) - R^T(d)| < \Delta_0$ (де великих m).
 (Ймовірність великих відхилень даних величин стає малою).



Def
 Вибірку $(k_1, \dots, k_n)$ назовемо Δ -придатною, якщо $\forall d \in D: |R^e(d) - R^T(d)| < \Delta$
Def
 Вибірку $(k_1, \dots, k_n)$ назовемо не придатною, якщо $\exists d \in D: |R^e(d) - R^T(d)| \geq \Delta$

якщо R^e потрапило в коридор $\Rightarrow$ видірка
придатна.


Для повного розуміння використання
 R^e замість R^T потрібно розглянути
2 питання:

1) Якщо видірка Δ -придатна, то що потрібно
поставити замість "...": $|R^T(d^e) - R^T(d^*)| < \dots$?

2) Для заданого m (одієму видірки): Яка ймовірність не придатних
видірок ϵ - сумарна ймов-ть всіх видірок, що не придатні
Потрібно вказати який значення ϵ залежить від m і інших
параметрів: $\epsilon \in \mathbb{R}(m, \dots)$

Розглянемо 1) (по ділету):

Видірка придатна; Ко скільки відрізняється $R^T(d^*)$ і $R^T(d^e)$?




Наприклад:

$$|R^T(d^e) - R^T(d^*)| < 2\Delta$$

Доведемо: Δ

Потрібно розглянути 3 положення R^e і R^T
1) Обидві точки $R^e(d^*)$ і $R^e(d^e)$ нижче за $R^T(d^*)$ і $R^T(d^e)$



не різниче не перевищує Δ

$$\text{тобто } |R^e(d^e) - R^T(d^e)| < \Delta \text{ по } (*)$$


$$R^e(d^e) \text{ нижче за } R^e(d^*) \Rightarrow$$

$$R^e(d^*) \text{ вище за } R^e(d^e)$$

$$\Rightarrow |R^T(d^*) - R^e(d^*)| < |R^T(d^e) - R^e(d^e)|$$

$$\Rightarrow |R^T(d^*) - R^T(d^e)| \leq \Delta$$


2) Обидві точки $R^e(d^*)$ і $R^e(d^e)$ вище за $R^T(d^*)$ і $R^T(d^e)$



$\rightarrow$ Аналогічно до 1)

$$\Rightarrow |R^T(d^*) - R^T(d^e)| \leq \Delta$$

3) $R^T(d^*)$ нижче за $R^e(d^e)$; $R^e(d^*)$ вище за $R^T(d^*)$ і $R^e(d^e)$



$R^e(d^*)$ не може бути нижче за $R^e(d^e)$,
а $|R^e(d^*) - R^T(d^*)| < \Delta$ і $\Rightarrow$


$$|R^T(d^e) - R^e(d^e)| < \Delta$$

$$\Rightarrow |R^T(d^*) - R^T(d^e)| \leq 2\Delta$$

$$\Rightarrow |R^T(d^*) - R^T(d^e)| \leq 2\Delta \text{ якщо видірка придатна!}$$

5. $R^T(d) = \sum_{k \in K} p(k|x^0) \cdot W(k, d) \quad R^e(d) = \frac{1}{m} \sum_{i=1}^m W(k_i, d)$

Δ -нпрм. вярба: $\forall d \in \mathcal{D} [|R^T(d) - R^e(d)| \leq \Delta]$ (где $\mathcal{D}$ — множество d)



Как обеспечить Δ -непрмную вярбу?


$P(\exists d: |R^T(d) - R^e(d)| \geq \Delta) = ?$

→ рассмотрим всю функцию $R^T(d), R^e(d)$.

Видно, что $P(|R^T(d) - R^e(d)| \geq \Delta) \leq \frac{\sigma_w^2}{m \cdot \Delta^2}$



тогда те, что мы указали на или-на



(все "погрешности" вярбы при d в $\mathcal{D}$)

$P(\exists d: |R^T(d) - R^e(d)| \geq \Delta) \leq \sum_{d \in \mathcal{D}} P(|R^T(d) - R^e(d)| \geq \Delta) \leq$

$\leq \sum_{d \in \mathcal{D}} \left(\frac{\sigma_w^2}{m \cdot \Delta^2} \right) = \frac{|\mathcal{D}| \cdot \sigma_w^2}{m \cdot \Delta^2}$

$$P[\exists d \mid |R^T(d) - R^E(d)| \geq \Delta] \leq \frac{|D| \cdot \sigma_w^2}{m \cdot \Delta^2}$$

$|D|$ - кількість можливих рішень
 σ_w^2 - оцінка зверху для дисперсії
 m - довжина вибірки
 Δ - допустима похибка.

В якій мірі використається це на практиці?

$\frac{\sigma_w}{\Delta}$ - відносна похибка. Нехай $\pm 1\%$ - ~~похибка~~ ^{похибка} значення
 точний ризик оцінено з наближенням $\leq \Delta$.

$$\frac{\sigma_w}{\Delta} = 10^2$$

Таке хочемо, щоб ймовірність некоректної вибірки була малою.
 Нехай таке ймовірність виходу за межі: $P[\exists d \mid |R^T(d) - R^E(d)| \geq \Delta] \leq \frac{|D| \cdot \sigma_w^2}{m \cdot \Delta^2} \leq 10^{-2}$

$$\frac{|D| \cdot \sigma_w^2}{m \cdot \Delta^2} \leq 10^{-2} \quad \frac{|D|}{m} \cdot 10^6 \leq 1, \quad \boxed{m \geq |D| \cdot 10^6}$$

При великих $|D|$ ~~то~~ ^{то} може бути таке дуже велике, але в деяких випадках це явно краще, ніж мінімізація точного ризику.

6. Сформулювати і обґрунтувати необхідні і достатні умови, яким мають задовольняти ум. ймовірності $p(x|y)$ і $p(y|x)$, щоб вони однозначно визначали спільні ймов-ті $p(x, y)$

Нехай y має $x \in X, y \in Y$ - випадкові величини.

$p(x, y)$ - визначає ймовірність пари x, y .
 $p(x, y) = p(x) \cdot p(y|x) = p(y) \cdot p(x|y)$

У загальному випадку $p(y|x), p(x|y)$ не визначають однозначно $p(x, y), p(x), p(y)$

Нам потрібно описати випадки, коли вони також визначаються

Визначимо граф Γ_X
 x', x'' - сусіди, якщо $\exists y^* \in Y [p(x', y^*) \neq 0, p(x'', y^*) \neq 0]$

Теорема

Якщо Γ_X складається із єдиної зв'язної компоненти, то $p(y|x)$ і $p(x|y)$ також визначають $p(x, y)$, а відносно $p(x), p(y)$.

А якщо Γ_X складається із багатьох зв'язних компонент, то $p(y|x)$ і $p(x|y)$ не визначають $p(x, y)$ і відносно $p(x), p(y)$.

Нехай x', x'' сусіди, то $p(x', y^*) \neq 0, p(x'', y^*) \neq 0$

$$\frac{p(x'/y^*)}{p(x''/y^*)} = \begin{cases} p(x', y^*) = p(x') \cdot p(y^*/x') = p(y^*) \cdot p(x'/y^*) \\ p(x'', y^*) = p(x'') \cdot p(y^*/x'') = p(y^*) \cdot p(x''/y^*) \end{cases}$$

$$= \frac{p(x') \cdot p(y^*/x') / p(y^*)}{p(x'') \cdot p(y^*/x'') / p(y^*)} = \frac{p(x')}{p(x'')} \cdot \frac{p(y^*/x')}{p(y^*/x'')}$$

$$\Rightarrow \text{Для двох сусідів: } \frac{p(x')}{p(x'')} = \frac{p(x'/y^*) \cdot p(y^*/x'')}{p(x''/y^*) \cdot p(y^*/x')} \quad (*)$$

Напишемо алгоритм для визначення $p(x)$ на основі $p(x|y)$ та $p(y|x)$.

⇒ Якщо граф Γ_x складається із єдиної зв'язної компоненти то в ньому існує зв'язне дерево.

1) Подуздувати зв'язне дерево


2) В ньому обрати довільну вершину x^* як корінь.

Зробити це дерево орієнтованим (визначити стрілки до корня)

$next(x)$ - вершина по стрілці яка веде від x в напрямку корня

3) Присвоїмо корню $g(x^*) = 1 = c \cdot p(x^*)$
здесь c - константа.

4) $x \in X$ - це така вершина для якої
 $g(next(x)) = c \cdot p(next(x))$



ймовірності не відомі але відоме відношення (4)

$$\Rightarrow g(x) = g(next(x)) \cdot \frac{p(x)}{p(next(x))} = c \cdot p(x)$$

Знаючи числа g

ми можемо виразити $p(x) = \frac{g(x)}{\sum_x g(x)}$

⊆ без дов.

В такому випадку, якщо багато зв'язних компонент то пара p -їх $p(x|y), p(y|x)$ не визначають точно $p(x, y)$

(на визначення з точністю якоюсь параметру:
по суті це буде сума зв'язних компонент)

$$[p(x/y), p(y/x)] \mapsto (p(x), p(y))$$

Т.е. ми шукаємо в рішеннях лінійної сист. рівнянь


$$p_x^*(x) \left\{ \begin{aligned} p(x) &= \sum_{y \in Y} p(y) p(x/y), \quad x \in X \end{aligned} \right. \quad (1)$$

$$p_y^*(y) \left\{ \begin{aligned} p(y) &= \sum_{x \in X} p(x) p(y/x), \quad y \in Y \end{aligned} \right. \quad (2)$$

Алгоритм не можна застосовувати на практиці, т.я. всі вирази та всі значення $x \in X, y \in Y$ - а це може бути неможливо.

Система рівнянь вирішуватимемо наступним чином:

- беремо довільний вектор $p^0(x)$
- підставляємо $p^0(x)$ в (2), отримуємо $p^1(y)$
- підставляємо $p^1(y)$ в (1), отримуємо $p^2(x)$



Нехай $p_y^*(y), p_x^*(x)$ - розв'язок системи р-нв.

Тоді: $\lim_{i \rightarrow \infty} \max_{x \in X} |p_i(x) - p_x^*(x)| = 0.$

Алгоритм можна в неадаптивному на практиці.

Але можна використати підхід до тримання алгоритму, який не вимагає такого об'єму пам'яті.

- визначено довідкове x_0
- генеруємо $y_1 = \text{rand } p(y/x_0)$
- генеруємо $x_1 = \text{rand } p(x/y_1)$

y_1 з розподілу $p_2(y)$, ...

На кожній кроці приймаємо випадкову вибірку з поточної ймовірності, а випадкову величину із заданого розподілу.

В результаті достатньо довгого марковського процесу, ми отримавши $x_i \mapsto \text{rand } p_x^*(x)$.

Зв'язок з алгоритмом (доведення)

$x \in X, y \in Y, p(x, y) \quad p_x(x/y), p_y(y/x)$

$x^0 \rightarrow p_{y/x}(y/x^0) : y^1$

$y^1 \rightarrow p_{x/y}(x/y^1) : x^1 \dots \rightarrow x^k \rightarrow y^{k+1} \rightarrow x^{k+1}$

y, x^k розподіли імов. $p_x^k(x)$. Тоді

$$p_y^{k+1}(y) = \sum_{x' \in X} \underbrace{p_{y/x}(y/x') p_x^k(x')}_{p_{x,y}(x', y)} \quad (1)$$

$$p_x^{k+1}(x) = \sum_{y' \in Y} p_{x/y}(x/y') \cdot p_y^{k+1}(y') \quad (2)$$

Хочемо отримати зв'язок $p^{k+1}(x)$ ($p^k(x)$). Підстав. 1 в 2.

$$p_x^{k+1}(x) = \sum_{y' \in Y} p_{x/y}(x/y') \cdot p_y^{k+1}(y') = \sum_{y' \in Y} p_{x/y}(x/y') \cdot \sum_{x' \in X} p_{y/x}(y'/x') \cdot p_x^k(x')$$

$$\neq \sum_{x' \in X} \sum_{y' \in Y} p_{x/y}(x/y') p_{y/x}(y'/x') p_x^k(x')$$

7.

12.2

$$\ominus \sum_{x' \in X} \sum_{y \in Y} p_{xy}(x/y) \cdot p_{yx}(y'/x') \cdot p_x^k(x') = p_x^{k+1}(x) \ominus$$

$A_{xx'}$ здесь p_{yx} не зависит от x'

$$|X|=n$$

$$\ominus \sum_{x' \in X} A_{xx'} p_x^k(x') \leftarrow \text{ум-ие матрицы на вектор.}$$

X -состояния ум-ия $\rightarrow$ переупорядочено их big 1 go $|X|$.

$$\text{For } i \quad p_x^k(1) = p_1^k, \quad p_x^k(2) = p_2^k, \quad \bar{p}^k, \quad \boxed{\bar{p}^{k+1} = A \bar{p}^k}$$

Положим, что при данных условиях $g_n A$ проще сходиться.
Попробуй в-ти $g_n A$.

$$1. \min_{i,j} A_{ij} = d > 0 \quad (\text{вс } e_n \text{ в } A \text{ - минимальности } > 0)$$

$$2. \forall \bar{z} \in \mathbb{R}^n: \sum_{i=1}^n z_i = \sum_{i=1}^n (A\bar{z})_i$$

$$A = \begin{pmatrix} - & \overset{x'}{\underbrace{-}_{=1}} & - & - \\ - & - & - & - \\ - & - & - & - \end{pmatrix}$$

$$\begin{aligned} \sum_{x' \in X} \sum_{y \in Y} p_{xy}(x/y') p_{yx}(y'/x') &= \\ &= \sum_{y \in Y} \left[\sum_{x \in X} p_{xy}(x/y') \right] p_{yx}(y'/x') = \sum_{y \in Y} p_{yx}(y'/x') = 1 \end{aligned}$$

$$\sum_{i=1}^n (A\bar{z})_i = \sum_{i=1}^n \sum_{j=1}^n A_{ij} z_j = \sum_{j=1}^n z_j \underbrace{\sum_{i=1}^n A_{ij}}_{=1} = \sum_{j=1}^n z_j$$

$$3. \forall \bar{z}: \bar{z} \geq 0: (A\bar{z})_i \geq 0, \forall i=1, n$$

$$A_{ij} \geq 0 \quad \forall i,j \Rightarrow (A\bar{z})_i \geq 0 \quad \forall i=1, n$$

Хотим показать, что $\bar{\Delta}^k = A \bar{p}^k - \bar{p}^k \rightarrow 0$

4. $\sum_{i=1}^n \Delta_i^k = 0 \quad \forall k \in \mathbb{N}$ за б.а. (2) $= \sum_{i=1}^n p_i^k$

▲ $\sum_{i=1}^n \Delta_i^k = \sum_{i=1}^n (A \bar{p}^k)_i - \sum_{i=1}^n p_i^k = 0$ ▲

$\bar{\Delta} = \bar{\Delta}^+ - \bar{\Delta}^-$, $\Delta_i^+ = \begin{cases} \Delta_i, & \Delta_i \geq 0 \\ 0, & \Delta_i < 0 \end{cases}$, $\Delta_i^- = \begin{cases} -\Delta_i, & \Delta_i < 0 \\ 0, & \Delta_i \geq 0 \end{cases}$

5. $\sum_{i=1}^n \Delta_i^+ = \sum_{i=1}^n \Delta_i^- = \frac{1}{2} \sum_{i=1}^n |\Delta_i|$

▲ очевидно ▲

6. $a \geq 0, b \geq 0, |a-b| = a+b - 2\min\{a, b\}$

▲ $a > b$: $|a-b| = a+b - 2\min\{a, b\} = a+b - 2b = a-b$
 $a \leq b$: $|a-b| = a+b - 2\min\{a, b\} = a+b - 2a = b-a$ ▲

$\bar{\Delta}^k = A \bar{x}^k - \bar{x}^k$

$\bar{\Delta}^{k+1} = A \bar{x}^{k+1} - \bar{x}^{k+1} = A(A \bar{x}^k - \bar{x}^k) - (A \bar{x}^k - \bar{x}^k) = A(A \bar{x}^k - \bar{x}^k) = A \bar{\Delta}^k$

Тогда рассмотрим величины:

$$\begin{aligned} \sum_{i=1}^n |(A \bar{\Delta})_i| &= \sum_{i=1}^n |(A \bar{\Delta}^+ - A \bar{\Delta}^-)_i| = \sum_{i=1}^n |(A \bar{\Delta}^+)_i - (A \bar{\Delta}^-)_i| = \\ &= \sum_{i=1}^n ((A \bar{\Delta}^+)_i + (A \bar{\Delta}^-)_i - 2\min\{(A \bar{\Delta}^+)_i, (A \bar{\Delta}^-)_i\}) = \\ &= \sum_{i=1}^n (A \bar{\Delta}^+)_i + \sum_{i=1}^n (A \bar{\Delta}^-)_i - 2 \sum_{i=1}^n \min\left\{ \sum_{j=1}^n \overset{\geq d}{A_{ij}} \Delta_j^+, \sum_{j=1}^n \overset{\geq d}{A_{ij}} \Delta_j^- \right\} \leq \\ &\leq \sum_{i=1}^n \Delta_i^+ + \sum_{i=1}^n \Delta_i^- - 2 \sum_{i=1}^n \min\left\{ \sum_{j=1}^n d \Delta_j^+, \sum_{j=1}^n d \Delta_j^- \right\} = \\ &= \sum_{i=1}^n |\Delta_i| - 2 \sum_{i=1}^n \min\left\{ \frac{1}{2} d \sum_{j=1}^n |\Delta_j|, \frac{1}{2} d \sum_{j=1}^n |\Delta_j| \right\} = 0 \end{aligned}$$

7.

n. 3

$$\textcircled{=} \sum_{i=1}^n |\Delta_i| - \sum_{i=1}^n d \sum_{j=1}^n |\Delta_j| = \sum_{i=1}^n |\Delta_i| - n \cdot d \cdot \sum_{i=1}^n |\Delta_i| =$$

$$= \sum_{i=1}^n |\Delta_i| (1 - nd)$$

сума модулів зменшилася в $(1 - nd)$ разів.
Віновидно $\Delta^k \rightarrow 0$.

$\bar{p}^k \rightarrow \bar{p}^*$
↑
переходна точка

$$A \bar{p}^k = \bar{p}^*$$

$$\bar{p}^k = \underbrace{A A A \dots A}_{k \text{ разів}} \bar{p}^0$$

$$A_{x/x'} = p_{x/x'}(x/x')$$



8. Експоненціальні випадкові величини. Вивести загальний вираз розподілу ймовірностей експ. вип. величини

Дано: X ; $p(x)$; $x \in \{0, 1, \dots, \infty\}$;
 $\uparrow$ відомо

$x \in X, y \in Y, p(x); p(y); p(x, y) = p(x) \cdot p(y)$.

$x \in \mathbb{R}; \int_{-\infty}^{+\infty} x p(x) dx = 0, \int_{-\infty}^{+\infty} x^2 p(x) dx = 1$ мат. сподівання = 0
дисперсія = 1

$$p(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} = N(0, 1).$$

Така гаусівська величина з (0, 1) має найбільшу ентропію (тобто можна передати максимальний об'єм інформації через $N(0, 1)$)

$x \in X, p(x); f_1, f_2, \dots, f_n; f_i: X \rightarrow \mathbb{R}$ базис експ. вип. величин

Ці функції f_i задані, відомо їх математичне сподівання і дисперсії.

Напишемо систему P :

$$P: \begin{cases} \sum_{x \in X} f_i(x) \cdot p(x) = \theta_i, & i = 1, \dots, n \\ \sum_{x \in X} p(x) = 1 \end{cases}$$

параметри експ. величини

$$P^* = \arg \max \left[- \sum_{x \in X} p(x) \cdot \log p(x) \right]$$

ентропія

Експоненціальна випадкова величина в базисі f з параметрами θ наз. вип. величиною з максимальною ентропією і задані цією системою.

Чи виникає воно точно? Так, бо це ми-ка винукла а ентропія строго зростає.

Максимум ентропії знаходиться за допомогою множників Лагранжа.

$$\Phi(p, \lambda_1, \dots, \lambda_n, \lambda_0) = - \sum_{x \in X} p(x) \log p(x) +$$

$$+ \sum_{i=1}^n \lambda_i \left(\sum_{x \in X} f_i(x) \cdot p(x) - \theta_i \right) + \lambda_0 \left(\sum_{x \in X} p(x) - 1 \right)$$

Рассмотрим гессиан x^*

$$\frac{\partial \varphi}{\partial p(x^*)} = -\log p(x^*) - 1 + \sum_{i=1}^n \lambda_i \cdot f_i(x^*) + \lambda_0 = 0$$

$$\sum_{i=1}^n \lambda_i f_i(x^*) + \lambda_0 - 1 = \log p(x^*)$$

$$e^{\sum_{i=1}^n \lambda_i f_i(x^*) + \lambda_0 - 1} = p(x^*)$$

$$e^{\lambda_0 - 1} = C; \text{ рассмотрим } \lambda = (\lambda_1, \dots, \lambda_n) \\ f = (f_1, \dots, f_n)$$

$$\Rightarrow p(x^*) = C \cdot \exp[\underbrace{\lambda \cdot f(x)}_{\text{вектора}}]$$

n.1

$$\kappa: \mathbb{T} \rightarrow K, \quad t \mapsto \kappa^T,$$
$$K(T')(t) = \int K(t), t \in T'$$

[ne bisogna, in altre

τ -структура mm-mm T. $\tau \subset 2^T$.

Таким образом, формулы 2-го порядка:

$$N(t) = \{t' \in T \mid t t' \in \tau\}$$

k - бул. б-ла, $p(k)^+?$ $T, \tau, p_{T'}(k(T'))$ ← исални шовирности
 $T \in \tau, k(T') \in k\tau$
 дигне

$$P \begin{cases} p_{T'}(k') = \sum_{\substack{k \in K \\ k(T') = k'}} p(k), \quad T' \in \mathcal{T}, k' \in K^{T'} & (\lambda(T', k')) \\ 1 = \sum_{k \in K^T} p(k) & (\lambda_0) \end{cases}$$

Scanned with CamScanner

$$p^* = \operatorname{argmax}_{p \in P} \left[- \sum_{k \in K} p(k) \log p(k) \right]$$

→ вимоги викладові не наші обов'язки T із заданою
структурою $\mathcal{T}$ і заданими локальними ймовірностями.
Якщо ситуація має рішення, то P -інтерпретація експоненціально-уважана
→ p^* -єдине
Рівняння з ген. ф-ти напружена.

$$\Phi(p, \lambda) = - \sum_{k \in K} p(k) \log p(k) + \sum_{T' \in \mathcal{T}} \sum_{k' \in K'} \lambda(T', k') \sum_{\substack{k \in K \\ k(T') = k'}} p(k) + \lambda_0 \sum_{k \in K} p(k)$$

F_2
 F_1
 F_0

$$\frac{\partial \Phi}{\partial p(k^*)} = 0.$$

Розглянемо 2-й випадок окремо (F_0).

$$\frac{\partial F_2}{\partial p(k^*)} = \begin{cases} 1, & k^*(T') = k' \\ 0, & k^*(T') \neq k' \end{cases}$$

(k', T' - фіксовані)

$$\frac{\partial F_1}{\partial p(k^*)} = \lambda(T', k^*(T'))$$

$$\frac{\partial F_0}{\partial p(k^*)} = \sum_{T' \in \mathcal{T}} \lambda(T', k^*(T'))$$

Тепер розглянемо весь вираз:

g.


п. 2

$$\frac{\partial \Phi(p, \lambda)}{\partial p(k^0)} = -\log p(k^0) - 1 + \sum_{T' \in \mathcal{Z}} \lambda(T', k^0(T')) + \lambda_0 = 0 \quad \forall k^0 \in \mathcal{K}$$

$$\log p(k) = C + \sum_{T' \in \mathcal{Z}} \lambda(T', k(T'))$$

$$p(k) = \prod_{T' \in \mathcal{Z}} g_{T'}(k(T'))$$

Φ -я величин k -сти значений выражается как продукт Φ -й малой k -сти значений.



Наблюдение перемещения структуры 2-го порядка.

$$p(k) = \prod_{t' \in \mathcal{Z}} g_{t'}(k_t, k_{t'})$$

10. Марківські властивості відсого поля і відсого самплер відсого поля

T' - множина об'єктів, K - множина міток; $k: T \rightarrow K$ - розмітка
 $k \in K^{T'}$ - множина всіх розміток; $k(t)$ - мітка об'єкта $t, t \in T'$
 $T' \subset T$ - віконце
 $k(T')$ - фрагмент розмітки k на віконці T' (зуження ф-ї k на підмножині T')
 $k(T'): T' \rightarrow K$
 $k(T')(t) = \begin{cases} k(t), & t \in T' \\ \text{не визначено} & \text{для } t \notin T' \end{cases}$


Відсого випадкове поле тако ототожнюють з марківськими, але це не зовсім так і мітками є різниці.

Насправді марківські вип. поле є підмножиною відсого випадкових полів.



Доводимо, що для структур 2-го порядку тобто коли кожне віконце складається тільки із двох об'єктів і ці об'єкти сусідні

Нехай $T \subset T \times T, t, t' \in T, N(t^*) = \{t' | t, t' \in T\}$ - множина сусідів t^*
 $\bar{N}(t^*) = \{t' | t \neq t' | t, t' \in T\}$ - множина не сусідніх об'єктів з t^*
 T - множина всіх пар сусідніх об'єктів.



У відсогому випадковому полі нас цікавить

$$p(k) = \prod_{t, t' \in T} g_{t, t'}(k(t), k(t'))$$

складна ф-я великої кількості змінних.

У марківському випадковому полі нас цікавить

$$p(k(t^*) / k(T \setminus \{t^*\})) = p(k(t^*) / k(N(t^*)), k(\bar{N}(t^*))) \ominus$$

$k(T \setminus \{t^*\})$ - розмітка не сусідів t^*

$k(N(t^*))$ - розмітка сусідів t^*

$k(\bar{N}(t^*))$ - розмітка не сусідів t^*

Марковість насправді означає, що мітка об'єкта t^* насправді не залежить від $k(\bar{N}(t^*))$

$p(k(t^*)) = p(k(t^*)/k(N(t^*)))$ - неправильне твердження.

"Якщо задати t^* (придати зірочки) t^* :
сусідів t^* то t^* залежить тільки від сусідів і
не залежить від не сусідів".

$$\Theta \Big\{ \text{по Байесу} \Big\} = \frac{p(k(t^*), k(N(t^*)), k(\bar{N}(t^*)))}{\sum_{k(t^*) \in K} p(k(t^*), k(N(t^*)), k(\bar{N}(t^*)))} =$$

$$= \left\{ \begin{array}{l} \text{Возіємо множину } T^N = \{t, t^* \in T\} - \text{множина пар} \\ \text{і } T^{\bar{N}} = T \setminus T^N - \text{множина всіх решти пар} \end{array} \right\} \text{ і сусідів } t^*$$

$$= \prod_{t \in N(t^*)} g_{tt^*}(k(t), k(t^*)) \cdot \prod_{t, t' \in T^{\bar{N}}} g_{tt'}(k(t), k(t')) =$$

$$\sum_{k(t^*) \in K} \prod_{t \in N(t^*)} g_{tt^*}(k(t), k(t^*)) \cdot \prod_{t, t' \in T^{\bar{N}}} g_{tt'}(k(t), k(t'))$$

че не залежить
від $k(t^*)$ то
можна винести
і скоротити

$$= p(k(t^*)/k(N(t^*)))$$

$$\Rightarrow \text{ми знаємо} \quad p(k(t^*)/k(T \setminus \{t^*\})) = C \cdot \prod_{t, t' \in T} g_{tt'}(k(t), k(t'))$$

$\Rightarrow$ марк. виш. поле не
підмножина піддового виш. поля.


Інверсійний самплер інверсного поля

T - множина об'єктів; K - множина міток; $k: T \rightarrow K$ - розмітка.
 $k(t)$; $\mathcal{T} \subset T \times T$ - структура укріплення;

$$N(t) = \{t' \in T \mid t' \in \mathcal{T}\}$$

Виходимо з того, що g -я k (розмітка) є вип. інверсним полем:

$$\Rightarrow \text{Існує } p(k) = \prod_{t' \in \mathcal{T}} g_{t'}(k(t), k(t'))$$



← Кожен з цих об'єктів знаходиться в якому-то стані, але ці стани приховані.

Для кожного об'єкта заданий сигнал, що він виражається $x(t)$; $x: T \rightarrow K$.

Сигнал залежить від стану об'єкту, при цьому

якщо стан об'єкта заданий, то він не залежить від станів всіх інших об'єктів.

Цей залежить x від k заданий $p_t(x/k) \leftarrow$ відома.

$$p(x/k) = \prod_{t \in T} p_t(x(t)/k(t))$$

Може бути обчислена $p(k/x) = \frac{p(k) \cdot p(x/k)}{\sum_{k \in K^T} p(k) \cdot p(x/k)}$ (**)

x некая дуга казавати зображенням.

«Всього обчислень» і починає саме складність, бо вона залежить від великої кількості розміток

Завдання полягає в тому, що для заданого зображення x спробувати про вл-ті прихованої розмітки і знайти розмітку.

$$x^* \mapsto f(k) \text{ вл-ть прихованої розмітки. по розпізнаю.}$$

Ця розмітка і генерується за допомогою інверсного самплера як це зробити?

- 1) Буду-яким чином нумеруються об'єкти $t_1, t_2, t_3, \dots, t_n$
 - 2) Буду-яким чином вибирається початкова розмітка k_0
 - 3) На основі k_0 будується нова розмітка k_1 , яка відрізняється від k_0 тільки в об'єкті t_1 , потім будується нова розмітка k_2 , на основі k_1 , відрізняється від k_1 тільки в об'єкті $t_2, \dots$, і будується нова розмітка k_n на основі k_{n-1} , яка відрізняється від k_{n-1} в об'єкті t_n
- Цей весь процес є однією ітерацією інверсного самплера, а це **крок**

$$t_1, t_2, \dots, t_i, \dots, t_n$$

$$\bar{k}_0, \bar{k}_1, \bar{k}_2, \dots, \bar{k}_{i-1}, \bar{k}_i$$

Крок

Як реалізується один крок?
 На основі $\bar{k}_{i-1}$ будується $\bar{k}_i$. В ця новий розбитті мітки всіх об'єктів, що не є t_i ! Вони не змінюються.
 $k_i(t) = k_{i-1}(t), t \neq t_i$, а $k_i(t)$ вибирається випадково відповідно $t = t_i$

до якоїсь розподілу ймовірностей.

Ми знаємо, що мітка в об'єкті t_i залишиться в усіх наступних об'єктах і від сигналу, що випромінює t_i

$$P\left(\underset{\substack{\uparrow \\ \text{мітка} \\ \text{в об'єкті } t_i}}{k} / \underset{\substack{\uparrow \\ \text{const}}}{x^*(t_i)}, \underset{\substack{\uparrow \\ \text{задано}}}{k(N(t_i))}\right) = \underset{\substack{\uparrow \\ \text{const}}}{C} \cdot \underset{\substack{\uparrow \\ \text{задано}}}{P_{t_i}(x^*(t_i)/k)} \cdot \prod_{t' \in N(t_i)} \underset{\text{задано}}{f_{t_i t'}(k(t_i), k(t'))}$$

Після достатньо великої кількості ітерацій гібридного семплера розбиття, що отримується є вим. розбиттям, що має цей **(**)** розподіл ймовірностей.

Рекоменданій щодо кількості ітерацій немає.

11.

$$T, K, k: T \rightarrow K, k \in K^T, p: K^T \rightarrow \mathbb{R}, p(k)$$

$$f_i: K^T \rightarrow \mathbb{R}, i \in J$$

$$p \begin{cases} \theta_i = \sum_{k \in K^T} f_i(k) p(k), i \in J \\ 1 = \sum_{k \in K^T} p(k) \end{cases}$$

$$p^* = \operatorname{argmax}_{p \in P} \left[- \sum_{k \in K^T} p(k) \cdot \log p(k) \right]$$

Розглянемо випадок, коли θ_i -невідоми, але відомі в вибірках $(k_1, \dots, k_m)$, то для них знайдемо щонайменше оцінку θ_i^* . Визначимо шлях макс. правдоподібності.

$$\theta \in \Theta; p(x/\theta); (x_1, \dots, x_m) = \bar{x}$$

$$p(\bar{x}/\theta) = \prod_{i=1}^m p(x_i/\theta)$$

$$\underset{\text{найб. гн. } \theta}{\theta^*} = \operatorname{argmax}_{\theta \in \Theta} p(\bar{x}/\theta) = \operatorname{argmax}_{\theta \in \Theta} \sum_{i=1}^m \log p(x_i/\theta)$$

Введемо вектор-функцію

$$f: K^T \rightarrow \mathbb{R}^n$$

$$P_\theta \begin{cases} \theta = \sum_{k \in K^T} f(k) \cdot p(k) \\ 1 = \sum_{k \in K^T} p(k) \end{cases}$$

$$P_\theta = \operatorname{argmax}_{p \in P_\theta} \left(- \sum_{k \in K^T} p(k) \log p(k) \right)$$

$$P = \{ P_\theta \mid \theta \in \mathbb{R}^n \}$$

P_θ - випадковий гн. вектор на P_θ

P - мн-ва P_θ (максим. ентроп. гн. $P_\theta \neq P_{\theta'}$)

$$\text{Візьмемо, } p_\theta(k) = C \cdot \exp(\lambda \cdot f(k)) = \frac{\exp(\lambda f(k))}{\sum_{u \in K^T} \exp(\lambda f(u))}$$

Задано:

$k_1, \dots, k_m$

$$\theta^* = \operatorname{argmax}_{\theta \in \mathbb{R}^n} \sum_{i=1}^m \log p_\theta(k_i)$$

Можно переформулировать

$$p^\theta = \operatorname{argmax}_{p \in \mathcal{P}} \sum_{i=1}^m \log p(k_i)$$

где $\mathcal{P}$ — все возможные законы распределения

$$\lambda^* = \operatorname{argmax}_{\lambda \in \mathbb{R}^n} \left(\sum_{i=1}^m \log \frac{\exp(\lambda \cdot f(k_i))}{\sum_{u \in \mathcal{K}} \exp(\lambda \cdot f(u))} \right) \quad \left(\text{т.е. } p_\theta(k_i) \text{ выражена в параметрах } \lambda \right)$$

$F(\lambda)$

$$F(\lambda) = \sum_{i=1}^m \lambda \cdot f(k_i) - \sum_{i=1}^m \log \sum_{u \in \mathcal{K}} \exp(\lambda \cdot f(u))$$

$$\frac{dF(\lambda)}{d\lambda^*} = \sum_{i=1}^m f(k_i) - \sum_{i=1}^m \frac{\sum_{u \in \mathcal{K}} \exp(\lambda^* \cdot f(u)) f(u)}{\sum_{u \in \mathcal{K}} \exp(\lambda^* \cdot f(u))} = 0$$

$$\sum_{i=1}^m f(k_i) - \sum_{i=1}^m \theta^* = 0$$

$\Downarrow$

$$\boxed{\theta^* = \frac{1}{m} \sum_{i=1}^m f(k_i)}$$

$\mathcal{K}$ - найбільш правдоподібне оцінювання параметрів
вільного поля

T - множина об'єктів, K - множина міток, $k: T \rightarrow K$ - розмітка
 $\bar{k} \in K^T$; $p: K^T \rightarrow \mathbb{R}$, $p(\bar{k})$

Запишемо експоненціальну випадкову величину у векторному
вигляді: $f: K^T \rightarrow \mathbb{R}^n$; f_i - дозосні f -її

$$\begin{cases} p(\theta) = \sum_{\bar{k} \in K^T} f(\bar{k}) \cdot p(\bar{k}) \\ 1 = \sum_{\bar{k} \in K^T} p(\bar{k}) \end{cases}$$

$$; p_\theta = \arg \max_{p \in P_\theta} \left[- \sum_{\bar{k} \in K^T} p(\bar{k}) \cdot \log p(\bar{k}) \right] -$$

- найбільш ентропійна вип. величина.

$$P = \{ p_\theta \mid \theta \in \mathbb{R}^n \}$$

Будь-яка із цих величин має такий вигляд:

$$p_\theta(\bar{k}) = C \cdot \exp(\lambda \cdot f(\bar{k})) = \frac{\exp(\lambda \cdot f(\bar{k}))}{\sum_{\bar{k} \in K^T} \exp(\lambda \cdot f(\bar{k}))}$$

визначення
C, до
 $\sum p = 1$
(нормування)

Запишемо оцінку θ :

$$\theta^* = \arg \max_{\theta \in \mathbb{R}^n} \sum_{i=1}^m \log p_\theta(\bar{k}_i) - \text{Таким чином } p_\theta \text{ макси-}$$

-мізує ймов-ть вибірки $\bar{k}_1, \dots, \bar{k}_m$

Тобто задача полягає в тому, щоб знайти таке θ і підставити в
символу p_θ , щоб ймов-ть p_θ максимізувала ймовірність

вибірки $\bar{k}_1, \bar{k}_2, \dots, \bar{k}_n$

Але зовсім пошуку θ^* ми можемо сформулювати задачу
пошуку такої p -її

$$p^* = \arg \max_{p \in P} \sum_{i=1}^m \log p(\bar{k}_i) \quad \text{чи функції виглядають таким чином}$$

або можемо ще третє формулювання:

$$\lambda^* = \arg \max_{\lambda \in \mathbb{R}^n} \sum_{i=1}^m \log \left(\frac{\exp(\lambda \cdot f(\bar{k}_i))}{\sum_{\bar{k} \in K^T} \exp(\lambda \cdot f(\bar{k}))} \right)$$

↑ вектор λ градієнта

Будь-яка із цих формулювань однозначно
визначає інше.

Розглянемо зазор λ^* :

Позначимо
$$\sum_{i=1}^m \log \frac{\exp(\lambda \cdot f(\bar{k}))}{\sum_{\bar{k} \in K^T} \exp(\lambda \cdot f(\bar{k}))} = F(\lambda)$$

$$F(\lambda) = \sum_{i=1}^m (\lambda \cdot f(\bar{k}_i)) - \sum_{i=1}^m \log \sum_{\bar{k} \in K^T} \exp(\lambda \cdot f(\bar{k}))$$

$$\frac{dF(\lambda)}{d\lambda} = \sum_{i=1}^m f(\bar{k}_i) - \sum_{i=1}^m \frac{\sum_{\bar{k} \in K^T} \exp(\lambda^* f(\bar{k})) \cdot f(\bar{k})}{\sum_{\bar{k} \in K^T} \exp(\lambda^* f(\bar{k}))} = 0$$

$\downarrow$
де λ^*
має виконувати θ^*

$$\Rightarrow \sum_{i=1}^m f(\bar{k}_i) - \sum_{i=1}^m \theta^* = 0$$

$$\Rightarrow \theta^* = \frac{1}{m} \sum_{i=1}^m f(\bar{k}_i)$$

Перенесемо цей результат на гідсове вип. поле:

$p(\bar{k})$ - гідсове вип. поле.

$P_{T'}(s)$ - ймов-ть того, що виконки T' буде зайняте фрагмент s .

Відома $P_{T'}(s) = \sum_{\bar{k} \in K^T} f_{T',s}(\bar{k}) \cdot p(\bar{k})$ - матричний.

Зазначо $\bar{k}_1, \bar{k}_2, \dots, \bar{k}_m$.

$\Rightarrow$ очікуваною
кандидатом правдоподібності
є $P_{T'}(s)$ і:

$$P_{T'}^* = \frac{1}{m} \sum_{i=1}^m f_{T',s}(\bar{k}_i)$$

Або нехай ми знаємо скільки разів на виконки T' здійснювали
фрагмент s

Позначимо це $n_{T'}(s)$

$$\Rightarrow P_{T'}^*(s) = \frac{n_{T'}(s)}{\sum_{s \in K^{T'}} n_{T'}(s)}$$

13.

 $X, K, p(x, k), D, w(k, d)$

$$R(q) = \sum_{x \in X} \sum_{k \in K} p_{xk}(x, k) w(k, q(x)) \leftarrow q(x) \text{ - детерм. стратегія}$$

дет. стратегія - для кожного вхідного сигналу вибав одноразове рішення.

рандомізоване стратегія - для кожного вхідного сигналу існує розподіл ймовірностей рішень. $q: D \times X \rightarrow R$
 $(q(d/x))$

$$R(q) = \sum_{x \in X} \sum_{k \in K} p_{xk}(x, k) \sum_{d \in D} \underline{q(d/x)} w(k, d)$$

Приклад китайської задачі, де p_k краєві, шук q_{det} .



$K \in \{1, 2\}$ p_1, p_2 - апіорні імов. ставів, $p(x/1), p(x/2)$
 дані об'єкту китайської мови $\Rightarrow$ машина розпізнавання. Рух
 але існує і інші підхід. На вхід системи подаються не
 безпосередньо одбиті, а спочатку подаються достатньо велика t -св
 об'єктів, про які відомо, що вони знаходяться в стані $k=1$,
 аналогічно, наступ одбитів із $k=2$. Оцінка помилки розпізна
 окремо. p_{max1} p_{max2} . Знаючи тільки $\max \{p_{max1}, p_{max2}\}$.
 китайської задачі.

Приклад

X

X_0
● $k=1$
 $k=2$

$$p(X_0/k=1) = 20\%$$
$$p(X_0/k=2) = 30\%$$



наш - услов. вероятность
конкретного ответа,
если задаться в 1 шаг

- Принимаю det стратегию.

Всё на X_1 мы даём $k=1$, на $X_2 \rightarrow k=2$.

где X_0 мы сразу всё даём. $q(X_0)=1 \Rightarrow \text{наш}_2 = 30\%$

$$q(X_0)=2 \Rightarrow \text{наш}_1 = 20\%$$

Итого наша = 30% (где q_{det})

- Принимаю rand стратегию

на X_1 даём $k=1$, на $X_2 \rightarrow k=2$.

а где X_0 - даём по вероятности

$$q(k=1/X_0) = \frac{2}{5} \quad \text{наш}_1 = \frac{3}{5} \cdot 0.2 \cdot 100\% = 12\%$$
$$q(k=2/X_0) = \frac{3}{5} \quad \text{наш}_2 = \frac{2}{5} \cdot 0.3 \cdot 100\% = 12\%$$

Итого наша = 12% (где q_{rand})

$$\underline{12\% < 30\%}$$

14. Задачі розпізнавання при неможливості визначити статистичну модель об'єкта розпізнавання. Функція ризику стратегії. Придатні та непридатні стратегії

Дослід тріли формулювати задачі розпізнавання так:

$X \in X$ - множина об'єктів, $k \in K$ - множина станів

(x, k) - випадкова пара; $p(x, k)$ - ймов-ть сигналу у стані k .

$g: X \rightarrow K$ - стратегія, яка для кожного x дає стан: $g(x) \in K$.

$w: K \times K \rightarrow \mathbb{R}$ - ф-я втрат (штрафу).

$w(k, k')$ - виграш іграшки, який випадає, якщо об'єкт знаходиться в стані k' , але насправді він знаходиться у стані k .

Якщо об'єкт знаходиться в стані k , а система прийняла рішення $g(x) \Rightarrow$ існує ризик прийняття рішення.

$$R(g) = \sum_{x \in X} p(x) \sum_{k \in K} p(k/x) w(k, g(x)) = \sum_{x, k} p(x, k) w(k, g(x)) -$$

- детермінований ризик (використовується детермінована стратегія: тобто спостережний сигнал x стратегія вибирає конкретне рішення).

Розглянемо випадок рандомізованої стратегії

$$g: K \times X \rightarrow \mathbb{R};$$

$g(k/x)$ - якщо система розпізнавання спостерігає x то вона приймає випадкове рішення щодо того, що об'єкт знаходиться у стані k відповідно до розподілу ймов-ей $p(x, k)$.

$$R(g) = \sum_{\substack{x \in X \\ k \in K}} p(x, k) \sum_{k' \in K} g(k'/x) w(k, k') - \text{рандомізований ризик.}$$

Цей ризик є лінійною ф-єю стратегії

Вона тут в якості співмножника

На дані використовуватимемо лише рандомізовані стратегії.

Задача з неповністю відомою стат. моделлю

Нехай зараз нам відомо $p(x, k)$ з точністю деякого параметра $\theta \in \Theta$.


$p(x, k, \theta)$; $\theta \in \Theta$ назвемо моделлю об'єкта.

Θ - множина моделей (кінцева)

$\Rightarrow \nexists$ ранд. ризик. залежить не тільки від g , а й від θ

$$R(g, \theta) = \sum_{\substack{x \in X \\ k \in K}} p(x, k, \theta) \sum_{k' \in K} g(k'/x) \cdot w(k, k'). \quad (*)$$

Ми маємо зрозуміти як розрізнявати об'єкти, якщо статистична модель об'єкту задана не повністю, а з деякого параметру θ . Цей ризик (*) вказує тепер не просто чим, а чим θ -ію: як ризик заповнення θ моделі




І (*) сам по собі не може сказати, що яким стратегією кроку за ікми при певній θ .

Приклад

x - зображення букви, k - ім'я букви
 θ - положення букви в полі зору.

Місце за все: розподіл ймов-ей $p(x, k, \theta)$ на множині імен букви не залежить від θ : тобто ймов-ть появи букви "А" в якому місці така ж сама як і ймовірюєть появи "А" в яких місцях




$$\text{Тобто } p(x, k, \theta) = p(k) \cdot p(x | \theta).$$

Рішення: Якщо задано зобр x^* , то візнюєть цього зображення приймаєть рішення, що на якому зображенні на малюванні букви з іменем k^* , що вираховуєть таким чином.
 $x^* \mapsto k^* = \arg \max_k [\max_{\theta} p(x^* / k, \theta)]$ - чим: знайти ім'я букви.


→ Яке найбільш ймовірно положення букви "А", потім "Б" ... ?
 → отримують числа і вибирають найбільше.

Таком можна по іншому задати задачу:
 На основі x^* знаходиться не тільки ім'я букви, а й положення.
 $x^* \rightarrow (k^*, \theta^*) = \arg \max_{(k, \theta)} p(x^*, k / \theta)$ - чим: знайти ім'я букви і її положення

Стратегія g^0 поз. неприємною, якщо $\exists g^* \neq \theta [R(g^*, \theta) < R(g^0, \theta)]$



У тут g^0 оптимальна



У тут g^0 неприємне

Стратегія g^0 поз. продуктивно, якщо $\forall g^* \neq \theta [R(g^0, \theta) < R(g^*, \theta)]$

15.


Быть может наша теорема

 $x \in X, y \in Y, f: X \times Y \rightarrow \mathbb{R} \quad f(x, y)$

$$\min_{x \in X} \max_{y \in Y} f(x, y) \geq \max_{y \in Y} \min_{x \in X} f(x, y)$$

В результате получим, если $f(\bar{x}, \bar{y})$, то "=".

$$(x^0, y^0) \text{ — saddle point, } \min_x \max_y f(x, y) = f(x^0, y^0) = \max_y \min_x f(x, y)$$

 $x \in X, k \in K, p(x, k, \theta), \theta \in \Theta$, θ — модель (не обязательно бин. ден.-изв.)

$$q: K \times X \rightarrow \mathbb{R}, q(k/x), q \in Q, w(k, k') \in \mathbb{R}$$

$$R(q, \theta) = \sum_{x \in X} p(x, k; \theta) \sum_{k' \in K} q(k/x) w(k, k')$$

→ риск стратегии при модели θ

Теорема $q^0 \in Q$.Тоги ако $\exists q' \in Q \quad \forall \theta \in \Theta [R(q', \theta) < R(q^0, \theta)]$ (q^0 — невыгодная стратегия)


$$\text{ако } \exists \tau: \Theta \rightarrow \mathbb{R}: \tau(\theta) \geq 0, \sum_{\theta \in \Theta} \tau(\theta) = 1: [q^0 = \operatorname{argmin}_{q \in Q} \sum_{\theta \in \Theta} \tau(\theta) R(q, \theta)]$$

q^0 — байесовская

Если для стратегии q это невыгодное априори решение, и ни одна стратегия не θ байесовская и невыгодное решение.

 $q^0 \in Q$

$$F(\tau, q) = \sum_{\theta \in \Theta} \tau(\theta) [R(q, \theta) - R(q^0, \theta)]$$

 $F(\tau, q)$ — оценка выигрыша стратегии q при выборе модели θ и q^0 .

$F(\tau, q)$ - минимален по q и максимален по $\tau \Rightarrow F(\tau^*, q^*)$
 $\Rightarrow$ оптимальное значение функции.

$$\exists (\tau^*, q^*) : q^* = \arg \min_q F(\tau^*, q)$$

$$\tau^* = \arg \max_{\tau} F(\tau, q^*)$$

Лб.


$$F(\tau^*, q^*) \leq 0$$

$$\forall \tau \in T [F(\tau, q^*) = 0] \Rightarrow \forall \tau \in T [\min_{q \in Q} F(\tau, q) \leq F(\tau, q^*) = 0] \Rightarrow$$

$$\Rightarrow \max_{\tau \in T} \min_{q \in Q} F(\tau, q) \leq 0 \Rightarrow F(\tau^*, q^*) \leq 0$$

Тогда можно рассмотреть Q в зависимости от q^* .

Добавим правило еще в том, что глобально
и минимально.



$$F(\tau^*, q^*) < 0$$



q^* - невыгодна

$$F(\tau^*, q^*) = 0$$



q^* - выгодна

$$1. q^* \text{ - выгодна} \Rightarrow F(\tau^*, q^*) = 0 \quad \leftarrow \text{def. выгод. состояние}$$

$$\exists \tau^* \forall q \in Q \left[\sum_{\theta \in \Theta} \tau^*(\theta) R(q, \theta) \leq \sum_{\theta \in \Theta} \tau^*(\theta) R(q^*, \theta) \right] \Rightarrow$$

$$\Rightarrow \exists \tau^* \forall q \in Q \left[0 \leq \sum_{\theta \in \Theta} \tau^*(\theta) (R(q, \theta) - R(q^*, \theta)) \right] \Rightarrow$$

$$\Rightarrow \forall q \in Q [F(\tau^*, q) \geq 0] \Rightarrow \forall q \in Q [\max_{\tau \in T} F(\tau, q) \geq 0] \Rightarrow$$

$$\Rightarrow \min_{q \in Q} \max_{\tau \in T} F(\tau, q) \geq 0 \Rightarrow F(\tau^*, q^*) \geq 0, \text{ and } F(\tau^*, q^*) \leq 0 \Rightarrow F(\tau^*, q^*) = 0$$

15.

n. 2

2. $F(\tau^*, q^*) = 0 \Rightarrow q^*$ - saddle point exists.

$$\min_{q \in Q} F(\tau^*, q) = 0 \Rightarrow \min_{q \in Q} \sum_{\theta \in \Theta} \tau^*(\theta) [R(q, \theta) - R(q^*, \theta)] = 0 \Rightarrow$$

$$\Rightarrow \min_{q \in Q} \sum_{\theta \in \Theta} \tau^*(\theta) R(q, \theta) - \sum_{\theta \in \Theta} \tau^*(\theta) R(q^*, \theta) = 0 \Rightarrow$$

$$\Rightarrow \sum_{\theta \in \Theta} \tau^*(\theta) R(q^*, \theta) = \min_{q \in Q} \sum_{\theta \in \Theta} \tau^*(\theta) R(q, \theta) \Rightarrow q^* \text{ - saddle point}$$

3. q^* - weakly $\Rightarrow F(\tau^*, q^*) < 0$

$$\exists q^1 \in Q : \forall \theta \in \Theta [R(q^1, \theta) - R(q^*, \theta) < 0] \Rightarrow$$

$$\Rightarrow \exists q^1 \in Q \max_{\theta \in \Theta} [R(q^1, \theta) - R(q^*, \theta)] < 0 \Rightarrow$$

$$\Rightarrow \exists q^1 \in Q \max_{\tau \in T} \sum_{\theta \in \Theta} \tau(\theta) [R(q^1, \theta) - R(q^*, \theta)] < 0 \Rightarrow$$

$$\Rightarrow \min_{q \in Q} \max_{\tau \in T} F(\tau, q) < 0 \Rightarrow F(\tau^*, q^*) < 0$$

$$\begin{aligned} & \max_{i \in I} x_i, \text{ ?} \\ & d_i \geq 0, \sum_{i \in I} d_i = 1 \end{aligned}$$

$$\max_{d_i, i \in I} \sum_{i \in I} d_i x_i, \text{ ?}$$

$$\max_{x_i} \sum_{i \in I} d_i x_i = \max_{i \in I} x_i!$$

4. $F(\tau^*, q^*) < 0 \Rightarrow q^*$ - weakly

$$F(\tau^*, q^*) = \max_{\tau \in T} F(\tau, q^*) = \max_{\tau \in T} \sum_{\theta \in \Theta} \tau(\theta) [R(q^*, \theta) - R(q^*, \theta)] =$$

$$= \max_{\theta \in \Theta} [R(q^*, \theta) - R(q^*, \theta)] < 0$$

$$\forall \theta [R(q^*, \theta) < R(q^*, \theta)]$$

 $\Rightarrow q^*$ - weakly

Що з цього слідує?

$p(x, k; \theta)$;

$$k^0 = \underset{k \in \mathbb{N}}{\operatorname{argmax}} \sum_{\theta \in \Theta} \tau(\theta) p(x, k; \theta).$$

→ Якщо не хотімо порівнювати на непериндні сфери, k^0 варто шукати так.

Складніше лише в знаходженні $\tau(\theta)$.

16. Привести приклади небажаних заход розпізнавання: мініма-
кські заходи (minimax deviation) - заходи та інші. Показати, що страте-
гії рішень цих заход є багатовимірними, тобто не є неперервними

$X \in X$ - множина станів, що випромінює об'єкт.
 $K \subset K$ - множина станів об'єкта.
 $p(x, k, \theta)$ - ймовірність, визначена до деякого параметра θ (моделі)
 $\theta \in \Theta$ - множина моделей.

$g: K \times X \rightarrow \mathbb{R}$ - стратегія; $g: X \mapsto \arg \min_k g(k/x), g \in Q$

Запишемо ризик $R(g, \theta)$.

$$R(g, \theta) = \sum_{x \in X} \sum_{k \in K} p(x, k, \theta) \cdot \sum_{k' \in K} g(k'/x) w(k, k')$$

Знаємо $g^* = \arg \min_{g \in Q} \sum_{\theta \in \Theta} \tau(\theta) \cdot R(g, \theta)$

$\tau(\theta) \geq 0$, всі моделі, $\sum_{\theta \in \Theta} \tau(\theta) = 1$; $\tau: \Theta \rightarrow \mathbb{R}$.

$\tau \in T$ - множина всіх
вагових ф-ій.

Однозначний вибір стратегії потребує $|K| \cdot |X|$, а однозначний
вибір g^* потребує $|\Theta|$ (якщо $|\Theta| < |K| \cdot |X|$)

Потрібно з'ясувати як це все не вгадувати, а отримувати
збалансовано.

Приклад

Ми хочемо, щоб наша стратегія g була такою, що
 $\forall \theta \in \Theta [R(g, \theta) \leq C]$: тобто така g^* , яка урівнює ризик
в незалежності від θ


Хочемо знайти таке мінімальне C при якому це виконає
 вийде. $R(g, \theta) \leq C, \theta \in \Theta$

Якщо стратегія g задана, то чому має дорівнювати C для виконання
 нерівності?

$$C = \max_{\theta \in \Theta} R(g, \theta)$$

Потрібно знайти $g^* = \arg \min_{g \in Q} [\max_{\theta} R(g, \theta)]$ - важливо те, що

це стратегія отримана таким чином не може бути не придатною



Вона мінімізує максимальний ризик
 Нехай q^* не припадає $\exists q^{**}$, що
 максимізує ризик за q^* .
 $\Rightarrow \max_{\theta} R(q^{**}, \theta) <$
 $< \max_{\theta} R(q^*, \theta) \Rightarrow$
 $\Rightarrow$ це порушить призначеність q^*


$\Rightarrow$ ми знаємо, що будь-яка стратегія є байєсівською або
 не призначеною
 $\Rightarrow q^*$ не є не призначеною (є байєсівською).

$\Rightarrow \exists \tau^* \in T [q^* = \arg \min_{q \in Q} \sum_{\theta \in \Theta} \tau^*(\theta) R(q, \theta)]$

$\tau^* = \arg \max_{\tau \in T} \left(\min_{q \in Q} \sum_{\theta \in \Theta} \tau(\theta) R(q, \theta) \right) = \Phi(\tau)$

одноразово вибрати τ , що мінімізує стратегію.

В залежності як введуть функції $R(q, \theta)$ та $\tau(\theta)$ завжди
 увігнута Φ (вона завжди без мін. коєр $\tau(\theta)$, що потім
 мінімізуються).



Алгоритм, що знаходить τ^*

1) $\tau^0 \in T$ Вибіримо довільне τ^0 (поганий вибір).
 де $i = 0, 1, \dots$ - ітераційний процес.
 На i -му кроці:


Для τ^i : $q^i = \arg \min_{q \in Q} \sum_{\theta \in \Theta} \tau^i(\theta) R(q, \theta)$.
 застосуємо стратегію $q^i(x) = \arg \max_{k \in K} \sum_{\theta \in \Theta} \tau^i(\theta) R(x, \theta)$.

Для $R(q^i, \theta)$: $\theta^* = \arg \max_{\theta \in \Theta} R(q^i, \theta)$.

Застосуємо крок суперградієнтного алгоритму
 збільшити $\tau(\theta^*)$ $\leftarrow$ Вона нас ірригів
 зменшити ваги $\tau(\theta)$, $\theta \neq \theta^*$ $\leftarrow$ моделі
 збільшувати

Отриманий алгоритм будувався на базі тих знань, що стратегія не може бути не прибутковою, відповідно вона є байєсовою, відповідно вона мінімізує ризик при деяких вагах. Ті ваги, що беруть там участь + рішенням певної максимізаційної задачі.

Іще один приклад застосування міні-макс підходу



Є деяка стратегія, яка дає досить гарний результат для всіх $\theta \in \Theta$ крім якоїсь особливо неприємної моделі θ^* .


І ще кепським θ^* така, що навіть стратегія, що намається мінімізувати ймовірно помилкового розв'язування гілки для θ^* всередині дає поганий результат.

Та стратегія, що оптимізована тільки на θ^* краща, за ту яка буде для всіх $\theta \in \Theta$ крім θ^* гарний рез-т, але вона сильно поганий дає рез-т для решти $\theta \in \Theta$.

Якщо створювати принципам міні-макс, то буде одразу та, що оптимізована на θ^* (до її максимуму немає за максимуму гіб, що для всіх, крім θ^*).

Практичний приклад з шрифтами

Нехай є замовник. Він поставив задачу розробити систему розпізнавання шрифту Θ_1 . Інженер зробив це, але потім замовник вирішив додати один шрифт Θ_2 .



результат, що
вийшла стратегія, яка
зроблена тільки для шрифту Θ_1
на шрифті Θ_2

Виявилось, що стратегія, яка
робить добре розпізнавання
 Θ_1 погано розпізнавала Θ_2 .


результат, що
вийшла стратегія, яка
зроблена тільки для Θ_1

Тому почала задача розробити таку систему розпізнавання шрифтів (стратегія) що давала потім трошки кращий рез-т для Θ_1 , але задовільний для Θ_2 .

Приклад

minimax deviation strategy.

Нехай маємо таку ситуацію.



Величина ризику стратегії, що мінімізує ймов-ть помилкового розпізнавання, для цієї моделі.

Величина ризику стратегії, що мінімізує ймов-ть помилкового розпізнавання, для цієї моделі.

Це крива $\min_{\theta \in \Theta} R(q, \theta)$

Задача полягає в тому, щоб для заданого проміжку Δ побудувати стратегію q -я ризику якої повністю лежить у цьому проміжку Δ і при тому, щоб Δ було мінімальним. Тоді: Знайти $\min \Delta$ при цьому виконуватиме.

$$R(q, \theta) - \min_{\theta} R(q, \theta) \leq \Delta$$

Δ можна знайти так:

$$\Delta = \max_{\theta \in \Theta} [R(q, \theta) - \min_{\theta} R(q, \theta)] \text{ і потрібно знайти}$$

$$q^* = \arg \min_q \max_{\theta \in \Theta} [R(q, \theta) - \min_{\theta} R(q, \theta)]$$

Тими самими судженнями (в попередніх прикладах можна показати, що q^* не є непрямою)

$$\Rightarrow \text{це } q^*: q^* = \arg \min_q \sum_{\theta \in \Theta} \tau^*(\theta) [\quad]$$

Для чого q -ї існує сідова точка: певний набір θ

Цей набір θ :


$$q^* = \max_{q \in T} \min_{\theta} \sum_{\theta \in \Theta} \tau(\theta) [\quad]$$

Увага q -я $\Rightarrow$ її максимум може бути знайдений тим же іншим методом уваги до максимізації

17.

$$f: \mathbb{R}^n \rightarrow \mathbb{R}^n$$

Правото съвършено в точките $\bar{x}_0 \in \mathbb{R}^n$ означава, че $f(\bar{x}_0)$ е екстремум в $\bar{x}_0$.



$$1) f(\bar{x}_0) = l(\bar{x}_0)$$

$$2) \forall \bar{x} \in \mathbb{R}^n: f(\bar{x}) \geq l(\bar{x})$$

$$\nabla_s f(\bar{x}_0) = \nabla l(\bar{x}_0) = \vec{a}$$

↑ съвършено φ-ї f в точките $\bar{x}_0$

$$\nabla_s f: \mathbb{R}^n \rightarrow \mathbb{R}^n$$

$$\bar{x}_0 \in \mathbb{R}^n, \exists \nabla f(\bar{x}_0) \Rightarrow \nabla_s f(\bar{x}_0) = \nabla f(\bar{x}_0)$$

Връзки с извода

$$1) \nabla_s (df(\bar{x})) = d \nabla_s f(\bar{x}), \bar{x} \in \mathbb{R}^n, d \geq 0$$

$$\Delta g(\bar{x}) = df(\bar{x})$$

$$\bar{x}_0, \nabla_s f(\bar{x}_0) \Rightarrow l(\bar{x}): \begin{cases} l(\bar{x}_0) = f(\bar{x}_0) \\ l(\bar{x}) \leq f(\bar{x}), \bar{x} \in \mathbb{R}^n \end{cases}$$

$$\begin{cases} d l(\bar{x}_0) = d f(\bar{x}_0) = g(\bar{x}_0) \\ d l(\bar{x}) \leq d f(\bar{x}) = g(\bar{x}), \bar{x} \in \mathbb{R}^n \end{cases}$$

$$\Downarrow$$

$$l_2(\bar{x}) = d l(\bar{x}),$$

$$\nabla_s g(\bar{x}_0) = \nabla l_2(\bar{x}) = d \nabla l(\bar{x}) = d \nabla_s f(\bar{x}_0) \quad \Delta$$

$$2) f_1(\bar{x}), f_2(\bar{x}), g(\bar{x}) = f_1(\bar{x}) + f_2(\bar{x})$$

$$\nabla_s g(\bar{x}) = \nabla_s f_1(\bar{x}) + \nabla_s f_2(\bar{x})$$

$$\nabla f_1(\bar{x}_0), \nabla f_2(\bar{x}_0)$$

$$\begin{cases} l_1(\bar{x}_0) = f_1(\bar{x}_0) \\ l_2(\bar{x}_0) = f_2(\bar{x}_0) \\ l_1(\bar{x}) \leq f_1(\bar{x}) \\ l_2(\bar{x}) \leq f_2(\bar{x}) \end{cases} \quad \bar{x} \in \mathbb{R}^n$$

$$l(\bar{x}) = l_1(\bar{x}) + l_2(\bar{x})$$

$$l(\bar{x}_0) = f_1(\bar{x}_0) + f_2(\bar{x}_0) = g(\bar{x}_0)$$

$$l(\bar{x}) = f_1(\bar{x}) + f_2(\bar{x}) = g(\bar{x}), \quad \bar{x} \in \mathbb{R}^n$$

$$\nabla g(\bar{x}_0) = \nabla l(\bar{x}_0) = \nabla l_1(\bar{x}_0) + \nabla l_2(\bar{x}_0) = \nabla f_1(\bar{x}_0) + \nabla f_2(\bar{x}_0)$$

$$3) f_1(\bar{x}), f_2(\bar{x}), g(\bar{x}) = \max\{f_1(\bar{x}), f_2(\bar{x})\}, \quad \nabla g(\bar{x}_0) = ?$$

$$\nabla f_1(\bar{x}_0), \nabla f_2(\bar{x}_0)$$

$$\begin{cases} l_1(\bar{x}_0) = f_1(\bar{x}_0) \\ l_1(\bar{x}) \leq f_1(\bar{x}) \\ l_2(\bar{x}_0) \leq f_2(\bar{x}_0) \\ l_2(\bar{x}) \leq f_2(\bar{x}) \end{cases}, \quad \bar{x} \in \mathbb{R}^n$$

$$\bullet \text{ Если } f_1(\bar{x}_0) > f_2(\bar{x}_0) \Rightarrow l_1(\bar{x}_0) = f_1(\bar{x}_0) = g(\bar{x}_0)$$

$$l_1(\bar{x}) \leq f_1(\bar{x}) \leq \max\{f_1(\bar{x}), f_2(\bar{x})\} = g(\bar{x}) \Rightarrow l_1(\bar{x}) \leq g(\bar{x})$$

$$\nabla g(\bar{x}_0) = \nabla l_1(\bar{x}_0) = \nabla f_1(\bar{x}_0)$$

$$\bullet f_2(\bar{x}_0) \leq f_1(\bar{x}_0) \Rightarrow \nabla g(\bar{x}_0) = \nabla f_2(\bar{x}_0)$$

$$\text{Узнавательно: } f_i(\bar{x}), \quad i = \overline{1, m}, \quad g(\bar{x}) = \max_{i = \overline{1, m}} f_i(\bar{x})$$

$$\nabla g(\bar{x}_0) = \left\{ k^* = \operatorname{argmax}_k f_k(\bar{x}_0) \right\} = \nabla f_{k^*}(\bar{x}_0)$$

18. Сформулювати процес субградієнтного спуску і основну його властивість

Нехай $f: D \rightarrow \mathbb{R}$. Вектор g наз-ся субградієнтном f -ї в x тогди $x \in D$, якщо $\forall y \in D$ виконується

$$f(y) \geq f(x) + g^T \cdot (y - x)$$

Субдиференціалом f в точці x наз-ся множина всіх субградієнтів f в точці x і позначається $\partial f(x)$

Нехай $f: D \rightarrow \mathbb{R}$ - випукла f -я. Заміняючи в градієнтному методі градієнт на субградієнт отримуємо:

$$x_{k+1} = x_k - \alpha_k g_k, \quad g_k \in \partial f(x_k) \quad (1)$$

Головна перевірка: замкнуто для f випуклої f -ї

Головний недолік: експоненціальна збіжність отримуємо тільки в дуже малих випадках. Числовості збіжність дуже повільна.

Головна проблема: на вихідну від градієнтного спуску не можна гарантувати, що $g_k \rightarrow 0$, навіть, якщо $x_k \rightarrow x^*$ скожується

На дані:

- f - випукла на D f -я
- f - неперервна по лінійцю з константою L , інакше всі субградієнти f рівномірно обмежені на D константою L .
- Відстань від пот. наближення до наближеної точки мінімумом обмежено R . $\|x_0 - x^*\| \leq R$

Способи вибору кроку: (резу).

- Константний (постійний): $\alpha_k = \alpha$.
- Розбітний реф: $\alpha_k \rightarrow 0, \sum_{i=0}^{\infty} \alpha_k = \infty$
- Розбітний реф: $\sum_{i=0}^{\infty} \alpha_k = \infty, \sum_{i=0}^{\infty} \alpha_k^2 < \infty$
збіжний реф
- Нормований: $\alpha_k = \frac{f_k}{\|g_k\|}$; f_k - одна із вищевказаних. позитивностей.

Основна нерівність субградієнтного спуску

$$f_k = \min_{1 \leq i \leq k} f(x_i);$$

$$\begin{aligned} \|x_{k+1} - x^*\|^2 &= \|x_k - x^*\|^2 - 2\alpha_k g_k^T (x_k - x^*) + \alpha_k^2 \|g_k\|^2 \leq \\ &\leq \|x_k - x^*\|^2 - 2\alpha_k (f(x_k) - f(x^*)) + \alpha_k^2 L^2 \leq \\ &\leq \|x_0 - x^*\|^2 - 2 \sum_{i=0}^k \alpha_i (f(x_i) - f(x^*)) + L^2 \sum_{i=0}^k \alpha_i^2 = \end{aligned}$$

$$= \|x_0 - x^*\|^2 - 2(\varphi_k - f(x^*)) \sum_{i=0}^k d_i + L^2 \sum_{i=0}^k d_i^2$$

$\Rightarrow$ Таким образом:

$$\varphi_k - f(x^*) \leq \frac{R + L^2 \sum_{i=1}^k d_i^2}{2 \sum_{i=1}^k d_i} \quad (2)$$

Теорема (про здійсненість субградієнтного спуску).

Якщо f - вивукла на D φ -я, x^* - точка мінімуму f на D , f - неперервна по топології γ компактності L , $\|x_0 - x^*\| < R \Rightarrow$ для кожного набраного набліження по (1):

- При $d_k = d$: $\lim_{k \rightarrow +\infty} \varphi_k - f(x^*) \leq \frac{dL^2}{2}$
- При $d_k \rightarrow 0$. $\sum_{k=1}^{\infty} d_k = \infty$: $\varphi_k - f(x^*) \rightarrow 0$

▲ Перше твердження виводиться безпосередньо підстановкою $d_k = d$ і граничним переходом:

Для другого в силу $d_i \rightarrow 0$ існує N_1 : $\forall k > N_1$ $d_i < \frac{\varepsilon}{L}$, а в силу $\sum_{i=0}^{\infty} d_i = \infty$ існує N_2 : $\forall n > N_2$ $\sum_{i=0}^n d_i > \frac{R}{\varepsilon}$ таким чином для $k \geq \max\{N_1, N_2\}$ справедливо:

$$\varphi_k - f(x^*) \leq \frac{R + L^2 \sum_{i=1}^k d_i^2}{2 \sum_{i=0}^k d_i} \leq \frac{R}{2 \sum_{i=0}^k d_i} + \frac{L^2 \cdot \varepsilon \cdot \sum_{i=0}^k d_i}{2 \cdot \sum_{i=0}^k d_i} <$$

$$< \frac{R}{2 \cdot \frac{R}{\varepsilon}} + \frac{\varepsilon \cdot \sum_{i=0}^k d_i}{2 \cdot \sum_{i=0}^k d_i} = \varepsilon$$

Отже (2) є φ -я змінних $d_1, \dots, d_k$. мінімізація якої буде давати гарантію набраної кращої здійсненості:

$$\text{Позначимо: } \varphi(d_1, \dots, d_k) = \frac{R + L^2 \sum_{i=1}^k d_i^2}{2 \sum_{i=1}^k d_i}$$

Диференціюючи по d_i :

$$\frac{\partial \varphi}{\partial d_i} = \frac{4L^2 d_i \sum_{i=1}^k d_i - 2(R + L^2 \sum_{i=1}^k d_i^2)}{(2 \sum_{i=1}^k d_i)^2} = 0$$

Рівняння існує лише для різних i , що має рівність всіх d_i . Використовуючи це отримуємо: $4L^2 k d_i^2 = 2R + 2L^2 k d_i^2$

$$\Rightarrow d_i = \frac{\sqrt{R}}{L \sqrt{k}}$$

19.

$x \in X, k \in K, p(x, k, \theta), \theta \in \Theta; q(k|x) \cdot ? , R(q, \theta)$

$q^* = R^*(\theta)$ - лучший по мощности элемент ($\min_{q \in Q} R(q, \theta)$)

$q^* = \operatorname{argmin}_{q \in Q} \max_{\theta \in \Theta} [R(q, \theta) - R^*(\theta)]$, где известно, что

$$\exists \tau^* \in T: q^* = \operatorname{argmin}_{q \in Q} \sum_{\theta \in \Theta} \tau^*(\theta) [R(q, \theta) - R^*(\theta)]$$

$$\tau^* = \operatorname{argmax}_{\tau \in T} \min_{q \in Q} \sum_{\theta \in \Theta} \tau(\theta) [R(q, \theta) - R^*(\theta)]$$

Внутренняя задача оптимизации с ограничениями ($\sum_{\theta \in \Theta} \tau(\theta) = 1, \tau(\theta) \geq 0 \forall \theta \in \Theta$)

де проблема оптимизации с ограничениями?

$\bar{x} = (x_1, \dots, x_i, \dots, x_n) \in \mathbb{R}^n, f: \mathbb{R}^n \rightarrow \mathbb{R}, g: \mathbb{R}^n \rightarrow \mathbb{R}^m, g$ -связующая $f(x)$

$\max_{x \in X} f(x) \cdot ? X = \{ \bar{x} / x_i \geq 0, \sum_{i=1}^n x_i = 1 \}; \bar{x}^* = \operatorname{argmax}_{\bar{x} \in X} f(x)$

$$\Pi_X(\bar{x}) = \operatorname{argmin}_{a \in X} \|\bar{x} - a\|^2$$


$$f_i \rightarrow 0$$

$$\sum_{i=1}^{\infty} f_i \Rightarrow \infty$$

f_i - цена

$\bar{x}_0, \bar{x}_1, \dots, \bar{x}_i, \bar{x}_{i+1}, \dots$

$\bar{x}_0 \in X$ (где строго определено)




Классы уже подготовили $\bar{x}^i$.

$$\bar{x}^i \mapsto \bar{x}_{i+1} = \bar{x}_i + \gamma_i \cdot g(\bar{x}_i) \mapsto \bar{x}_{i+1} = \Pi_{\mathcal{X}}(\bar{x}_{i+1}')$$

Повторяем шаг 1-го разб.

$$\lim_{i \rightarrow \infty} f(\bar{x}^i) = \max_{\bar{x} \in \mathcal{X}} f(\bar{x})$$



Задача минимизации τ^* .

$$\begin{cases} q^* = \arg \min_{q \in Q} \max_{\theta \in \Theta} [R(q, \theta) - R^*(\theta)] \\ \tau^* = \arg \max_{\tau \in T} \min_{q \in Q} \sum_{\theta \in \Theta} \tau(\theta) (R(q, \theta) - R^*(\theta)) \end{cases} \quad - F(\tau)$$

На i -м шаге имеем $\tau^i(\theta)$

$$1. q^i = \arg \min_{q \in Q} \sum_{\theta \in \Theta} \tau^i(\theta) (R(q, \theta) - R^*(\theta)), \text{ считаем } R(q^i; \theta)$$

$\frac{\partial}{\partial \tau(\theta)} g(\tau^i)$ считаем γ и т.д.

$$F(\tau) = \sum_{\theta \in \Theta} \tau(\theta) [R(q^i; \theta) - R^*(\theta)]$$

$$\frac{\partial F(\tau)}{\partial \tau(\theta)} = R(q^i; \theta) - R^*(\theta)$$

$$\tau^j(\theta) = \tau^i(\theta) + \gamma_j [R(q^i; \theta) - R^*(\theta)],$$

$$\tau^{i+1} = \Pi_{\mathcal{T}}(\tau^i)$$

Такой шаг на первом этапе минимизирует $\tau(\theta)$ для заданного q^i . Обратное, минимизируя $\tau(\theta)$ по θ в любой точке не может быть невыполнимо.